

管道缺陷自动检测与分类

李 灏, 王宏涛, 董晴晴

(南京航空航天大学机电学院, 江苏 南京 210016)

摘 要: 管道作为工业、核设施、石油天然气等领域中常用的物料输送手段, 在使用过程中极易出现各类缺陷, 传统的人工检测存在准确率低、效率低、成本高等缺点, 采用数字图像处理技术可以对管道图像进行自动检测与分类, 有效克服上述缺点。首先使用图像增强、图像分割、数学形态学以及边界跟踪对图像进行预处理, 在提取出缺陷区域的尺寸、形状和纹理特征后, 选择圆形度、凸度、离心率、熵、相关性和聚集度作为模式识别的特征向量, 最后综合使用基于粒子群优化的 K-means 聚类分析和统计模式识别分类器进行分类。使用文中的图像预处理算法可以成功的将管道缺陷提取出来, 达到管道缺陷自动检测的目的。基于粒子群优化的 K-means 聚类分析成功的将管道缺陷图像归为裂纹缺陷、管接头缺陷和孔形腐蚀三类, 相比于传统 K-means 算法, 聚类准确率分别提高 9%、16.7%、12.5%。综合使用基于粒子群优化的 K-means 聚类分析和统计模式识别分类器对管道缺陷进行分类, 三类缺陷的分类准确率均在 80% 以上, 其中管接头缺陷和孔形腐蚀的准确率达到 90% 以上。综上, 综合集成出了一套基于数字图像处理技术的管道缺陷自动检测与分类算法方案, 实验结果表明, 该算法方案具有自动化程度高、通用性强、准确率高的特点。

关 键 词: 管道缺陷检测; 图像处理; 粒子群优化; 聚类分析; 统计模式识别

中图分类号: TP 301.6

DOI: 10.11996/JGJ.2095-302X.2017060851

文献标识码: A

文 章 编 号: 2095-302X(2017)06-0851-06

Automated Pipe Defect Detection and Classification

LI Hao, WANG Hongtao, DONG Qingqing

(College of Mechanical and Electrical Engineering, Nanjing University of Aeronautics and Astronautics, Nanjing Jiangsu 210016, China)

Abstract: In the fields of industry, nuclear facilities, oil and gas, pipe is commonly used as the means of material delivery. And it is easy to appear various defects. The traditional manual detection system has the disadvantages of low accuracy, low efficiency and high cost. The digital image processing technology can automatically detect and classify the pipe image, thus effectively overcoming the above shortcomings. First, image enhancement, image segmentation, mathematical morphology and boundary tracking are used for image preprocessing. Then, after extracting the size, shape and texture features of the defective area, we choose the circularity, convexity, eccentricity, entropy, correlation and cluster tendency as the feature vector. Finally, K-means clustering analysis based on particle swarm optimization and statistical pattern recognition classifier is used for classification. Using the image preprocessing algorithm in this paper, we can successfully extract the pipe defects and achieve the purpose of automated pipe defect detection. K-means clustering analysis based on particle swarm optimization successfully clusters the pipe defect images into three categories which are crack defects, pipe joint defects and hole corrosion respectively. Compared with the traditional K-means algorithm,

收稿日期: 2017-06-09; 定稿日期: 2017-07-16

第一作者: 李 灏(1992-), 男, 山西太原人, 硕士研究生。主要研究方向为数字图像处理。E-mail: 2472109912@qq.com

通信作者: 王宏涛(1968-), 女, 吉林长春人, 教授, 博士, 博士生导师。主要研究方向为逆向工程。E-mail: mechtwang@nuaa.edu.cn

K-means clustering analysis based on particle swarm optimization can increase clustering accuracy by 9%, 16.7% and 12.5% respectively. The clustering analysis based on particle swarm optimization and the statistical pattern recognition classifier is used to classify the pipe defects. The classification accuracy of the three types of defects is more than 80%. The accuracy of pipe joint defects and hole corrosion is more than 90%. In summary, an integrated algorithm scheme for automated pipe defect detection and classification based on digital image processing technology is proposed. The experiments show that the algorithm scheme has the characteristics of high degree of automation, high versatility and accuracy.

Keywords: pipe defect detection; image processing; particle swarm optimization; cluster analysis; statistical pattern recognition

在一般工业、核设施、石油天然气、军事装备等领域中,管道作为一种有效的物料输送手段而得到广泛应用。由于天然气、化学物品的运输以及外界环境的侵蚀和破坏,管道极易出现裂纹、腐蚀等各种类型的缺陷,所以需要定期对管道进行检测和维护。人工检测存在成本高、效率低、耗时长等缺点,所以近年来,许多学者采用数字图像处理的方法进行管道缺陷的自动检测与分类。SINHA 和 FIEGUTH^[1-2]采用数学形态学方法进行图像预处理,在提取管道缺陷特征后,分别采用模糊 K 最近邻(k-nearest neighbor, K-NN)算法和模糊神经网络将管道缺陷分为裂纹缺陷、管接头缺陷和孔形腐蚀 3 种,并对上述 2 种算法进行了实验对比。WU 等^[3]针对下水管道,通过 Contourlet 变换和最大响应滤波器组提取管道特征,应用提升(RotBoost)算法对管道缺陷进行识别与分类。YANG 和 SU^[4]针对下水管道通过小波变换提取图像特征,运用支持向量机的分类方法对缺陷类型进行分类。ALAM 等^[5]通过图像灰度化、Sobel 边缘检测和数学形态学进行预处理,提取工业管道缺陷特征,根据缺陷区域的面积与周长比,结合统计学的方法对缺陷区域进行识别分类。SU 等^[6]针对下水管道提出了基于边缘检测的形态学分割算法(morphological segmentation based on


edge detection, MSED)进行特征提取,并对每类缺陷计算其形状特征,最后同样采用统计学的方法对缺陷进行识别分类。

本文综合集成了一套管道缺陷自动检测与分类算法方案,首先依次采用图像增强、最大熵阈值分割、数学形态学运算、边界跟踪对原始灰度图像进行预处理,然后提取管道缺陷的尺寸、形状以及纹理特征作为模式识别的特征向量,接下来采用基于粒子群优化的 K-means 聚类算法对图片数据进行聚类分析,将管道缺陷图片归为 3 类,分别是裂纹缺陷、管接头缺陷和孔形腐蚀。在对每类图片计算出特征向量后,运用基于统计学的欧氏距离分类器对样本图片进行分类。实验表明,该算法取得了很好效果。


1 图像预处理

1.1 图像增强


管道图像在拍摄、传输、接收过程中会产生各种噪声,本文采用中值滤波进行去噪处理。由于光照及成像系统性能的影响,采集到的图像对比度也不足,对目标图像的分割和识别十分不利,所以需要增强对比度来改善图像视觉效果,本文采用线性灰度拉伸来进行对比度增强。图像增强后的效果如图 1 所示。



(a) 原始管道缺陷图像



(b) 中值滤波



(c) 对比度增强

图 1 图像增强处理

1.2 图像分割

分析原始管道缺陷图像的灰度直方图, 其具有双峰性的特点, 宜采用阈值分割方法进行目标像素的提取, 常用的阈值分割方法有 OTSU 法、最大熵阈值分割法、迭代分割法和自适应阈值分割法。图 2 是 4 种算法分割效果对比, 可直观看出最大熵阈值分割算法^[7]处理效果最佳。


1.3 数学形态学运算

数学形态学是以形态为基础对图像进行分析的数学工具, 其基本思想是用具有一定形态的结

构元素, 去量度和提取图像中的对应形状, 以达到对图像分析和识别的目的^[8]。对于最大熵阈值分割后二值图像残存的孤立点和漏洞, 本文采取先进行形态学闭运算, 再进行形态学开运算的方法, 从而使图像只显示场景中的主要物体。形态学运算处理效果如图 3(a)所示。

1.4 边界跟踪

采用 8-邻接内边界跟踪算法^[9]对形态学运算后的图像(图 3(a))进行边界跟踪, 提取前景物体的轮廓, 效果如图 3(b)所示。




(a) 最大熵阈值分割

(b) 自适应阈值分割

(c) OTSU 阈值分割

(d) 迭代法阈值分割

图 2 分割算法效果对比



(a) 形态学运算处理效果

(b) 边界跟踪处理效果

图 3 图像预处理

2 图像特征提取

管道缺陷图像的特征主要包括尺寸特征、形状特征以及纹理特征。尺寸特征包括缺陷的面积、周长等。形状特征包括缺陷的圆形度、凸度及离心率等。纹理特征则包括从灰度共生矩阵中得到的熵、相关性和聚集度。本文提取圆形度(R)、凸度(Cov)、离心率(E)、熵(ENT)、相关性(COR)和聚集度(CLU)作为管道图像缺陷识别分类的特征。

2.1 尺寸特征提取

面积计算采用逐像素提取法。可以证明, 利用像素计数的方法来求缺陷区域面积, 不仅最简单, 而且也是对原始模拟区域面积的无偏和一致的最好估计^[10]。对图 3(a)中得到的二值图像进行逐

行逐列的扫描, 遇到白色像素记为 1, 遇到黑色像素记为 0, 最后统计 1 的个数即为裂纹的面积, 即

$$S = |P| = \sum_{(x,y) \in P} 1 \quad (1)$$

其中, $|P|$ 为区域 P 内的点数; (x, y) 为像素点的坐标; S 为面积。

缺陷区域周长根据边界跟踪得到的边界单位长链码来进行计算, 假设区域的边界链码为 a_1, a_2, \dots, a_n , 每个段 a_i 所代表的线段长度为 Δl_i , 则该区域边界的周长为

$$C = \sum_{i=1}^n \Delta l_i = n_e + \sqrt{2}(n - n_e) \quad (2)$$

其中, n_e 为链码序列中偶码个数; n 为链码序列中码的总个数。

2.2 形状特征提取

圆形度 R 是重要的形状特征^[11], 其定义为

$$R = \frac{4 \times \pi \times S}{C^2} \quad (3)$$

其中, S 为连通区域面积; C 为连通区域周长。当区域为圆形时, 圆形度为 1。

缺陷区域的凸度 Cov 定义为

$$Cov = \frac{S}{S_c} \quad (4)$$

其中, S 为连通区域的面积; S_c 为连通区域最小外

接矩形的面积。

缺陷区域的离心率 E 定义为^[12]

$$E = \frac{L_{i\max}}{L_{i\min}} \quad (5)$$

其中, $L_{i\max}$ 为缺陷区域的最大主轴长度; $L_{i\min}$ 为最小主轴长度。

2.3 纹理特征提取

图像的纹理特征是基于图像灰度共生矩阵(gray-level co-occurrence matrix, GLCM)的, 灰度共生矩阵 $P_{ij}(\theta, s)$ 被定义为图像中在给定的距离 S 和方向 θ 上像素 i 和 j 的灰度概率^[13]。灰度共生矩阵有 14 种对模式识别和分类有用的特征值, 但其并不是绝对相互独立, 一些特征值是多余的并且反而会影响模式识别和分类的效率。通过判别准则可得, 相关系数小于 0.5 且相互独立程度最高的特征分别是熵(ENT)、相关性(COR)和聚集度(CLU)。

$$ENT = -\sum_{i=1}^n \sum_{j=1}^n P_{ij} \cdot \log_2 P_{ij} \quad (6)$$

$$COR = \frac{\sum_{i=1}^n \sum_{j=1}^n (i \cdot j) P_{ij} - \mu_x \mu_y}{\sigma_x \sigma_y} \quad (7)$$

$$CLU = \sum_{i=1}^n \sum_{j=1}^n (i - \mu_x + j - \mu_y)^2 \cdot P_{ij} \quad (8)$$

其中,

$$P_{ij} = \frac{M_{ij}}{\sum_{i=1}^n \sum_{j=1}^n M_{ij}}, \quad \mu_x = \sum_{i=1}^n \sum_{j=1}^n i \cdot P_{ij},$$

$$\mu_y = \sum_{i=1}^n \sum_{j=1}^n j \cdot P_{ij} \quad (9)$$

$$\sigma_x = \sqrt{\sum_{i=1}^n \sum_{j=1}^n (i - \mu_x)^2 \cdot P_{ij}} \quad (10)$$

$$\sigma_y = \sqrt{\sum_{i=1}^n \sum_{j=1}^n (j - \mu_y)^2 \cdot P_{ij}}$$

本文选择距离 $s=1$ 和角度 $\theta=0^\circ, 45^\circ, 90^\circ, 135^\circ$ 建立灰度共生矩阵, 灰度共生特征在每个方向都由熵、相关性和聚集度构成, 4 个方向上熵、相关性和聚集度的平均值可以计算出来, 以此代表管道缺陷的纹理特征。

3 图像特征数据聚类分析

针对传统 K-means 聚类算法对初始聚类中心较为敏感、易收敛到局部极小值的缺点, 本文采

用一种基于粒子群优化的 K-means 聚类算法^[14], 对提取特征向量后的缺陷图像进行聚类分析, 将管道图片归为 3 类, 分别为裂纹缺陷、管接头缺陷和孔形腐蚀。具体算法步骤描述如下:

步骤 1. 初始化粒子群, 设置聚类数目 K , 最大迭代次数 M , 最大加权系数 w_{\max} 和最小加权系数 w_{\min} , 2 个学习因子 c_1 和 c_2 , 初始化个体最优适应度和群体最优适应度, 粒子群位置和初始速度, 初始化个体最优解和群体最优解。

步骤 2. 将每个样本随机分为某一类, 计算各类的聚类中心, 对初始粒子进行位置编码, 计算粒子的适应度, 反复进行 N 次, 共生成 N 个初始粒子群。

步骤 3. 针对每个粒子, 计算其当前位置处的适应度函数值, 比较当前位置处的适应度函数值和该个体最优历史最优位置 P_{id} 的适应度函数值, 如果更优, 则进行相应的更新。

步骤 4. 针对每个粒子, 将其当前位置处的适应度值和群体所经历的最好位置 P_{id} 的适应度函数值的适应度函数值, 如果更优, 则进行相应的更新。

步骤 5. 更新粒子的速度和位置, 其中惯性权重 w 的更新公式为

$$w = w_{\max} - t \times (w_{\max} - w_{\min}) / M \quad (11)$$

其中, t 为当前迭代次数。

步骤 6. 新个体的 K-means 优化。根据粒子的聚类中心编码, 按照最近邻法则, 来确定对应该粒子的聚类划分。

步骤 7. 判断是否达到结束条件(足够好的位置或最大迭代次数), 如果达到则结束, 并输出结果; 若没有, 则返回步骤 2。

4 基于统计学的管道缺陷图片分类

针对聚类分析后的结果, 对每类图像样本特征向量求平均值, 以此作为该类缺陷的特征向量, 即

$$\mathbf{w} = (w_1, w_2, w_3, w_4, w_5, w_6)^T = (R, Cov, E, ENT, COR, CLU)^T \quad (12)$$

对于每个测试样本, 应用 Euclidean 最小距离算法进行模式识别^[15], 即

$$d_i = (w_x - w_i)^2 / \sum_{j=1}^N (w_x - w_j)^2 \quad (13)$$

其中, $i=1, 2, \dots, N$, 且 $j \neq i$, 样本图片属于第 i 类缺陷当且仅当 d_i 是最小值。通过最小距离算法采取统计学的方式可以正确地进行管道缺陷识别和分类。

5 实验与分析

5.1 图像特征提取

随机取 3 类各一张缺陷图片进行预处理及特征提取, 以验证算法的通用性。预处理效果及特征提取结果如图 4~6 和表 1 所示。

5.2 基于粒子群优化的 K-means 聚类算法实验

随机取 80 张管道内壁图片, 包括 40 张裂纹缺

陷图片, 16 张管接头缺陷图片, 24 张孔形腐蚀图片。运用基于粒子群优化的 K-means 聚类算法对样本进行聚类分析, 设置粒子数 $N=50$, 学习因子 C_1 和 C_2 均为 1.2, 最大加权系数 $w_{\max}=0.9$, 最小加权系数 $w_{\min}=0.4$, 最大迭代次数 $M=200$, 类别数 $K=3$, 程序运行结果如图 7 所示, 由图可以得出当迭代次数为 200 时达到群体最优适应度值 920。




图 4 裂纹缺陷预处理效果




图 5 管接头缺陷预处理效果




图 6 孔形腐蚀缺陷预处理效果

表 1 特征向量提取结果

缺陷样本	w_1	w_2	w_3	w_4	w_5	w_6
裂纹左侧缺陷	0.090	0.290	6.608	1.250	-5.960	0.638
裂纹右侧缺陷	0.083	0.246	7.244	1.250	-5.960	0.638
管接头缺陷	0.081	0.739	25.750	2.418	0.031	2.952
孔形腐蚀缺陷	0.791	0.772	1.017	2.870	0.029	13.273

将该算法和基本的 K-means 聚类算法对管道图片聚类分析的结果进行比较, 统计算法准确率见表 2。

由表 2 可得, 相比于 K-means 聚类算法, 基于粒子群优化的 K-means 聚类算法在管道图片聚类分析中有着更高的准确率, 这是基于粒子群算




图 7 最优适应度随迭代次数的变化

表 2 两种聚类分析算法准确率(%)

聚类方法	聚类准确率		
	裂纹缺陷	管接头	孔形腐蚀
基于粒子群的 K-means 聚类算法	90.0	87.5	91.7
K-means 聚类算法	82.5	81.3	79.2

法优秀的全局搜索能力,较好地消除了聚类中心选择的随机性对聚类结果的影响,提高了聚类分析的准确率。

5.3 基于统计学的最小距离分类算法实验

在聚类分析之后,对每类缺陷样本的特征向量求其平均值,得到该类缺陷的特征向量,结果见表 3。

表 3 各类管道缺陷特征向量值

缺陷样本	W ₁	W ₂	W ₃	W ₄	W ₅	W ₆
裂纹缺陷	0.112	0.329	5.498	2.437	-2.219	6.099
管接头缺陷	0.093	0.546	17.252	2.450	-0.284	10.974
孔形腐蚀	0.744	0.765	1.158	2.441	-1.423	12.725

取管道裂纹、管道接头、孔形腐蚀测试样本图片各 30 张进行分类实验,分别得到基于统计学的最小距离分类器对管道图片识别分类的准确率,由于文献[1]同样将缺陷分为裂纹、管接头缺陷、孔形腐蚀 3 类,故将实验结果同文献[1]中模糊 K-NN 和模糊神经网络算法的实验结果作对比,结果见表 4。

表 4 分类算法准确率对比(%)

分类方法	分类准确率		
	裂纹缺陷	管接头	孔形腐蚀
Euclidean 最小距离算法	83.3	90.0	93.3
模糊 K-NN 算法	84.6	79.3	82.9
模糊神经网络	94.1	88.2	91.8

由表 4 可以看出,应用 Euclidean 最小距离分类算法在裂纹缺陷检测中的准确率和模糊 K-NN 算法相近,而模糊神经网络算法在裂纹缺陷检测中的准确率最高。在管接头和孔形腐蚀的检测中,基于统计学的 Euclidean 最小距离算法达到了最好的效果。

6 结 论

本文综合集成出了一套新的管道缺陷自动检测与分类算法方案,在对图像进行预处理的基础上,将圆形度、凸度、离心率、熵、相关性和聚集度作为管道缺陷模式识别的特征向量提取出

来,综合使用基于粒子群优化的 K-means 聚类分析和统计模式识别,取得了很好的管道缺陷检测和分类效果。

参 考 文 献

- [1] SINHA S K, FIEGUTH P W. Neuro-fuzzy network for the classification of buried pipe defects [J]. Automation in Construction, 2006, 15(1): 73-83.
- [2] SINHA S K, FIEGUTH P W. Segmentation of buried concrete pipe images [J]. Automation in Construction, 2006, 15(1): 47-57.
- [3] WU W, LIU Z, HE Y. Classification of defects with ensemble methods in the automated visual inspection of sewer pipes [J]. Pattern Analysis and Applications, 2015, 18(2): 263-276.
- [4] YANG M, SU T. Automated diagnosis of sewer pipe defects based on machine learning approaches [J]. Expert Systems with Applications, 2008, 35(3): 1327-1337.
- [5] ALAM M A, ALI M M N, SYED A A, et al. An algorithm to detect and identify defects of industrial pipes using image processing [C]//International Conference on Software, Knowledge, Information Management and Applications. New York: IEEE Press, 2014: 1-6.
- [6] SU T, YANG M, WU T, et al. Morphological segmentation based on edge detection for sewer pipe defects on CCTV images [J]. Expert Systems with Applications, 2011, 38(10): 13094-13114.
- [7] KAPUR B J N, SAHOO P K, WONG A K C. A new method for gray-level picture thresholding using the entropy of the histogram [J]. Computer Vision, Graphics and Image Processing, 1985, 29(3): 273-285.
- [8] LAGANIERE R. Open CV computer vision application programming cookbook [M]. Birmingham: Packt Publishing Limited, 2011: 103-107.
- [9] SONKA M, HLAVAC V, CENG R B D M. Image processing, analysis and machine vision [J]. Journal of Electronic Imaging, 2014(82): 685-686.
- [10] 章毓晋. 图像工程. 中册, 图像分析[M]. 北京: 清华大学出版社, 2005: 158-159.
- [11] 厉荣宣, 沈希忠, 张树行, 等. 基于图像处理的轴类零件表面裂纹检测[J]. 图学学报, 2015, 36(1): 62-67.
- [12] 吴挺, 鲁少辉, 韩旺明, 等. 基于主动式全景视觉传感器的管道内部缺陷检测方法[J]. 仪器仪表学报, 2015(10): 2258-2264.
- [13] GONZALEZ R C, WOODS R E. Digital image processing [M]. 3rd Edition. Beijing: Publishing House of Electronics Industry, 2006: 540-543.
- [14] 刘靖明, 韩丽川, 侯立文. 基于粒子群的 K 均值聚类算法[J]. 系统工程理论与实践, 2005, 25(6): 54-58.
- [15] ZHANG X L, LI T J, GAO H, et al. Research on vision inspection system for drainage pipeline's damage based on pattern recognition [C]//IEEE International Conference on Robotics and Biomimetics. New York: IEEE Press, 2008: 697-701.